

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

1. 服务结构与路由职责

一个可维护的 FastAPI 服务应把 HTTP 协议层与业务实现拆开。路由层负责接收请求、参数校验、依赖注入、状态码和响应模型；文档解析、向量检索、Prompt 构建等工作应交给 service / pipeline 层。

在 DocMind 类知识库服务中，可以将文档管理、检索、问答和健康检查分别放在不同 router 中。这样做的目的不是增加目录数量，而是让每个模块的边界清晰，便于单独测试和定位失败。

- router 不直接写 Chroma 查询，不负责切分文档，也不拼接系统 Prompt。
- service / pipeline 接收已经校验过的数据，编排 ingestion 或 RAG 流程。
- 响应模型由 Pydantic 定义，HTTP 状态码在 API 边界保持稳定。

记忆点：路由层回答“HTTP 请求怎么进来、结果怎么出去”，业务层回答“真正要做什么”。

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

2. 请求模型与参数校验

Pydantic 模型可以把常见边界提前挡在业务逻辑之外。例如 question 应去除纯空白，并设置合理的长度上限；分页、Top-K、文件类型和上传大小也应在进入核心流程前校验。

对于文件上传，除了扩展名，还应检查内容是否可解析。一个扩展名为 .pdf 的文件如果实际没有可提取文本，不能因为扩展名正确就进入 Embedding。

- question 不能为空，项目可设置最大长度，防止异常超长输入。
- 非法请求参数通常由 FastAPI/Pydantic 返回 422。
- 文件大小限制属于接口边界规则，例如项目可以限定为 10 MB。

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

3. 配置、依赖注入与敏感信息

运行配置应来自环境变量或 .env，而不是硬编码在 Python 文件中。API Key、Endpoint、模型名、数据目录以及 chunk / Top-K 等参数都可以统一进入 Settings 对象。

依赖注入适合提供数据库 Session、VectorStoreAdapter、EmbeddingClient 和 LLMClient。测试环境可以替换为 fake client，从而避免网络、真实密钥和调用费用。

- 真实 API Key 只写入 .env，.env 不提交 Git。
- .env.example 只提供变量名与占位值，可以提交仓库。
- 日志禁止打印 API Key、Authorization、完整文档正文和完整 Prompt。

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

4. 错误处理与稳定状态码

错误响应应尽可能稳定，让客户端可以根据 code 或状态码判断失败类型，而不是依赖内部异常文本。内部堆栈保留在服务端日志，外部只返回受控信息。

DELETE 成功时使用 204，并且不返回 JSON body。

状态码	典型含义
422	请求参数、文件格式、空文档或不可解析内容不符合规则。
404	请求的文档资源不存在。
409	内容 checksum 重复，文档已经被摄取。
502	Embedding / LLM provider 返回受控错误。
504	外部模型调用超时。

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

5. Liveness 与 Readiness

健康检查应区分“进程活着”和“服务已经具备工作条件”。/health/live 只证明 FastAPI 进程可以响应，不应依赖数据库或外部模型。

/health/ready 用来检查本地关键依赖，例如 SQLite 是否可查询、Chroma 数据目录是否可读写、必要模型配置是否存在。readiness 不应周期性调用收费的 LLM 或 Embedding API。

- live 正常时返回 200。
- ready 正常时返回 200；本地依赖未就绪时可以返回 503。
- 将外部付费 API 放进 readiness 会增加费用，并可能因网络波动造成误报。

FastAPI 服务工程指南

用于 DocMind RAG 样例检索的原创技术资料

6. 测试与 Fake Client

自动化测试应尽量可重复。对依赖外部模型的系统，测试最关键的手段是把 EmbeddingClient 和 LLMClient 抽象成接口，并在 pytest 中注入 deterministic fake。

API 测试可以使用 FastAPI TestClient 或 httpx。测试重点不仅是成功路径，也包括非法输入、provider 异常、超时、重复上传、拒答、来源引用校验和跨存储补偿。

- CI 中不需要真实 API Key。
- FakeEmbeddingClient 对相同文本应返回稳定结果。
- FakeLLMClient 可以记录调用次数，用于验证 Evidence Gate 拒答时确实没有调用 LLM。