

向量检索与证据门控手册

用于 DocMind RAG 样例检索的原创 RAG 资料

1. Embedding 与语义检索

Embedding

将文本映射为向量。向量检索并不是关键词精确匹配，而是通过向量距离寻找语义上接近的内容。文档 chunk 和用户 query 必须使用同一兼容 Embedding 模型，否则向量空间不可比较。

为了减少请求次数，文档摄取阶段通常对多个 chunk 批量生成 Embedding；查询阶段只需要为当前 question 生成一个 query embedding。

- 相同模型是文档向量与查询向量可比较的前提。
- Embedding 是检索阶段，不等同于 LLM 生成。

向量检索与证据门控手册

用于 DocMind RAG 样例检索的原创 RAG 资料

2. Chunk Size、Overlap 与来源定位

切分太小可能丢失上下文，太大则会把无关内容一起送进检索与 LLM。一个合理做法是先建立基线，再通过固定评测集比较不同参数。

本样例建议的基线是 chunk_size=700 字符、overlap=100 字符。PDF 为了保证引用可定位，应每页独立切分，不跨 page；Markdown 先按 heading 形成 section，再在 section 内切分。

切分参数不是越大越好，也不存在对所有语料都最优的固定值。

向量检索与证据门控手册

用于 DocMind RAG 样例检索的原创 RAG 资料

3. Cosine Distance、Top-K 与误解

当 Chroma collection 使用 cosine 距离时，distance 越小通常表示越相似。Top-K 表示返回前 K 个候选，不代表这些候选一定包含正确答案。

尤其面对完全无关的问题，向量库仍然可以机械地返回 Top-K。因此 distance 只能作为当前检索配置下的相关性信号，不能包装成“答案置信度”。

- rank=1 只代表当前查询中排序第一。
- Top-K 增大可能提高召回，也可能增加上下文噪声与 LLM 延迟。

向量检索与证据门控手册

用于 DocMind RAG 样例检索的原创 RAG 资料

4. Metadata、Document ID 与删除

每个 chunk 除了 text 和 vector，还应保存 metadata。最关键的是 document_id、filename、chunk_index，以及 PDF page 或 Markdown section。document_id 是文档生命周期管理的主键之一。

删除某个文档时，可以通过 document_id 过滤并删除全部向量。检索结果在进入 Context 前还应校验 document_id 是否仍存在于元数据数据库，从而忽略异常情况下留下的孤儿向量。

- PDF 使用 page 定位。
- Markdown 使用 section 定位。
- chunk_index 用于在同一文档中识别切分顺序。

向量检索与证据门控手册

用于 DocMind RAG 样例检索的原创 RAG 资料

5. Evidence Gate 与拒答

RAG 系统不应该因为“向量库返回了结果”就强行调用 LLM。Evidence Gate 在检索之后判断证据是否足够相关：没有结果，或者最佳结果的 distance 超过校准阈值时，可以直接返回固定拒答。

max_distance 不是概率，它应通过固定的可回答问题与无答案问题进行校准。拒答分支不调用 LLM，可以降低无依据生成和无效调用成本。

推荐固定拒答文本：“无法从当前资料确认”。